

UNIVERSIDAD DEL MAGDALENA

PROYECTO ICFES

MATEO DAVID VALENCIA CARO

SAMUEL DAVID LOPEZ ALVAREZ

ALBERT DEVANIS GASTELBONDO SUAREZ

ENRIQUE DE LA HOZ

ESTADISTICA INDUSTRIAL

2026

Resumen

Se construyó una base de datos integrada que permite identificar estudiantes que presentaron la prueba Saber 11 y posteriormente la prueba Saber Pro con un rezago de un año entre ambas evaluaciones.

Para la construcción de la base se utilizaron archivos oficiales descargados de la plataforma “Data ICFES”, manteniendo una línea temporal de los registros de las pruebas. En el caso del Saber 11 se incluyeron las bases de datos correspondientes a los periodos 2010-I a 2024-II. Por otro lado, para el Saber Pro se tomaron bases de datos correspondientes a los periodos 2014 a 2024; Sin embargo, los periodos 2014 y 2015 fueron excluidos de la base de datos integrada debido a que presentaban inconsistencias con los puntajes de las competencias.

La base de datos final conserva 40 variables, organizadas en 2 grupos principales: Variables sociales, orientadas a caracterizar las condiciones socioeconómicas de los estudiantes, y variables educativas, destinadas a analizar los resultados cuantitativos de las pruebas y la información de las instituciones educativas. Esta estructura nos permite desarrollar análisis mas completos y constituye una base reproducible para estudios posteriores.

Fuentes de datos

Se clasificaron los archivos descargados en la plataforma “Data ICFES” por prueba, año, archivos y periodos disponibles.

Saber 11

La base de datos de las pruebas Saber 11 está clasificada de manera individual por periodo asociado al calendario estudiantil, es decir, 1 archivo .txt por cada periodo. Además, se encontraron ambos periodos (20XX-1 y 20XX-2) para cada año (20XX).

Tabla 1. Clasificación por años y archivos saber 11

Saber 11		
Año	Archivos	Periodos
2010	Examen_Saber_11_20101 / Examen_Saber_11_20102	2010-I y 2010-II
2011	Examen_Saber_11_20111 / Examen_Saber_11_20112	2011-I y 2011-II
2012	Examen_Saber_11_20121 / Examen_Saber_11_20122	2012-I y 2012-II
2013	Examen_Saber_11_20131 / Examen_Saber_11_20132	2013-I y 2013-II
2014	Examen_Saber_11_20141 / Examen_Saber_11_20142	2014-I y 2014-II
2015	Examen_Saber_11_20151 / Examen_Saber_11_20152	2015-I y 2015-II
2016	Examen_Saber_11_20161 / Examen_Saber_11_20162	2016-I y 2016-II
2017	Examen_Saber_11_20171 / Examen_Saber_11_20172	2017-I y 2017-II
2018	Examen_Saber_11_20181 / Examen_Saber_11_20182	2018-I y 2018-II
2019	Examen_Saber_11_20191 / Examen_Saber_11_20192	2019-I y 2019-II
2020	Examen_Saber_11_20201 / Examen_Saber_11_20202	2020-I y 2020-II
2021	Examen_Saber_11_20211 / Examen_Saber_11_20212	2021-I y 2021-II
2022	Examen_Saber_11_20221 / Examen_Saber_11_20222	2022-I y 2022-II
2023	Examen_Saber_11_20231 / Examen_Saber_11_20232	2023-I y 2023-II
2024	Examen_Saber_11_20241 / Examen_Saber_11_20242	2024-I y 2024-II
2025	Examen_Saber_11_20251 / Examen_Saber_11_20252	2025-I y 2025-II

Saber Pro

Las pruebas saber pro se clasificaron de manera individual por año homologado o “genérico”, esto quiere decir que es un archivo .txt por año que contiene múltiples periodos. En este caso no todos los años tienen la misma cantidad de periodos.

Saber pro		
Año	Archivos	Periodos
2014	Examen_Saber_Pro_Genericas_2014	2014-2 y 2014-3
2015	Examen_Saber_Pro_Genericas_2015	2015-2 y 2015-3
2016	Examen_Saber_Pro_Genericas_2016	2016-2 y 2016-3
2017	Examen_Saber_Pro_Genericas_2017	2017-2 y 2017-3
2018	Examen_Saber_Pro_Genericas_2018	2018-2 ... 2018-4
2019	Examen_Saber_Pro_Genericas_2019	2019-4 ... 2019-6
2020	Examen_Saber_Pro_Genericas_2020	2020-2 y 2023-3
2021	Examen_Saber_Pro_Genericas_2021	2021-2 y 2021-3
2022	Examen_Saber_Pro_Genericas_2022	2022-2 ... 2022-6
2023	Examen_Saber_Pro_Genericas_2023	2023-1 ... 2023-4
2024	Examen_Saber_Pro_Genericas_2024	2024-1 ... 2024-4

Diccionarios de variables

El diccionario de variables fueron todas aquellas variables que se determinaron como importantes para la base de datos final, este diccionario fue anexado fuera del documento técnico.

Estrategia de Integración

Las dos pruebas se unieron mediante una serie de algoritmos en RStudio que se encargaron de Homologar, procesar, cruzar, unificar, detectar anomalías para eliminarlas y la limpieza de las bases de datos. Esto se organizo de esta manera ya que para un buen resultado final se necesita seguir ciertos pasos u ordenes, es decir que el algoritmo debe de trabajar paso por paso para consolidar la base de datos final.

Para integrar ambas pruebas en una sola base de datos cruzada se uso la base de datos oficial de cruces de la plataforma DataICFES; Esta es una base de datos que establece pares de identificadores únicos entre ambas pruebas “estu_consecutivo_sb11/sbPro” que corresponden al mismo estudiante, además, contiene el periodo en el que presentó la prueba.

Se decidió mantener la gran mayoría de registros de la base de datos cruzada, solo eliminando registros anormales como puntajes en decimales para mantener coherencia en la base de datos, al final se mantuvieron 1.400.614 filas (estudiantes que presentaron ambas pruebas).

Otra condición para mantener registros fue el rezago de un año entre pruebas, esto quiere decir que solo se mantuvieron registros de personas que realizaron primero las pruebas Saber 11 y luego un año después las pruebas Saber Pro.

Se encontraron estudiantes que presentaron más de una vez las pruebas, en estos casos se mantuvo sólo el primer resultado.

Limpieza y estandarización

A lo largo del proyecto y la consolidación de la base de datos se encontraron múltiples limitaciones principalmente relacionadas a las variables.

Saber 11

Partiendo por la prueba Saber 11 se tuvieron problemas con la consolidación y homologación de variables de los periodos, esto se debió principalmente a que en periodos anteriores no existían variables que en periodos posteriores fueron incorporadas.

En los periodos previos al 2014 muchos de los puntajes de las competencias fueron recalificadas ya que las 5 competencias que conocemos actualmente (Inglés, Ciencias naturales, Lectura crítica, Matemáticas y Ciencias sociales) fueron incorporadas como competencias “únicas” cuyo objetivo era agrupar antiguas competencias similares a partir del periodo 2014-2.

Para esto, se renombraron y homologaron las variables de los periodos del Saber 11, esto como objetivo de que el código uniera todas las bases de datos con las variables renombradas.

Saber Pro

En el caso de la Saber Pro, los problemas fueron muy similares ya que al haber cambios en las pruebas era necesario consolidar y homologar las variables en los periodos; Además de esto se encontraron inconsistencias a comparación de otras bases de datos en los puntajes Saber Pro. Estos fueron principalmente datos de puntajes dados con decimales (tipo 9.100000), estos datos correspondieron principalmente a los años 2014 y 2015, periodos en los que se calificaba de diferente manera (no de 0 a 300) por lo que se realizó una limpieza de estos periodos para eliminar inconsistencias.

Estas decisiones se tomaron con el objetivo de dejar una base de datos más limpia y clara para análisis posteriores.

Validación y calidad

La validación de la base de datos fue mediante análisis descriptivo y conteo de datos. Para esto se realizó un análisis de los datos validos en todas las bases de datos (Saber 11 y Saber Pro).

Variable	N_Validos	N_Perdidos_NA
S11_punt_c_naturales	1134595	266019
S11_punt_ingles	1134378	266236
S11_punt_lectura_critica	1134595	266019
S11_punt_matematicas	1134596	266018
S11_punt_sociales_ciudadanas	1134595	266019
S11_punt_global	787061	613553
S11_percentil_global	466449	934165
S11_estu_inse_individual	780336	620278
SP_estu_nse_individual	1138493	262121
SP_mod_comuni_escrita_punt	1390241	10373
SP_mod_competen_ciudada_punt	1400614	0
SP_mod_ingles_punt	1400143	471
SP_mod_lectura_critica_punt	1400614	0
SP_mod_razona_cuantitat_punt	1400614	0
SP_punt_global	1400603	11
SP_percentil_global	1399694	920
rezago_semestres	1400614	0

Donde la columna “variable” es el nombre homologado de las bases de datos, la columna “N_Validos” son los valores o datos que no presentaban anomalías y “N_Perdidos_NA” son los eliminados por anomalías y reemplazados por “NA”.

Se observo que tan solo se validaron y mantuvieron 1.400.614 datos ya que estos son los que no presentaron anomalías y además cumplían con la condición de rezago puesta que fue de un año entre pruebas.

Luego se realizó la matriz de cohortes para analizar los datos cruzados entre los periodos:

anio_s11	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024
2010	0	3	31216	21437	14723	12642	8936	7565	5685	5250	5195
2011	0	1	45873	32026	21025	16423	10905	8887	6423	5933	5870
2012	2	1	15190	47918	32231	23666	15206	12007	8312	7425	7364
2013	0	1	1345	16179	46915	35773	22001	16079	11250	9570	8690
2014	0	0	1360	1138	16827	52355	34200	23653	15782	12924	11435
2015	0	0	50	112	996	19045	51244	34481	22413	17539	14648
2016	0	0	31	26	60	1038	18756	50893	35446	26727	21584
2017	0	0	0	23	33	49	1222	17236	42918	39763	31235
2018	0	0	0	0	19	38	41	1254	14450	42704	44496
2019	0	0	0	0	0	37	28	55	1088	13171	45706
2020	0	0	0	0	0	28	33	28	51	1072	14516
2021	0	0	0	0	0	0	0	6	39	65	1144
2022	0	0	0	0	0	0	0	0	9	30	59
2023	0	0	0	0	0	0	0	0	8	9	34
2024	0	0	0	0	0	0	0	0	0	0	11
	2	6	95065	118859	132829	161094	162572	172144	163874	182182	211987

En la matriz podemos observar que el cruce de Saber 11 del año 2011 con el de Saber Pro del año 2016 es la que más cantidad de datos contiene, seguido del cruce del año 2019 del saber 11 con el año 2024 del Saber Pro.

Se presentaron censuras por la derecha por parte del Saber Pro ya que por el rezago las personas que presentaron las pruebas Saber 11 en los años 2024 y 2025 no es posible cruzarlas, esto se debe a que se tiene la limitación de bases de datos del saber pro, esta siendo hasta el año 2024.

Estos cruces fueron hechos con claves de estudiantes homologadas, ya que las Pruebas no publican datos personales, por lo que el algoritmo valido estas claves en la base de datos de cruces.

La calidad de la base de datos final está dada por la cantidad de datos faltantes en las variables, es decir, si hicieron falta poco porcentaje o en su defecto gran porcentaje de datos en algunas variables que se mantuvieron en la base de datos final, para esto se realizó un análisis de la base de datos obteniéndose:

Nombre de la variable	Porcentaje de valores faltantes
estu_consecutivo_sb11	0,0000%
periodo_sb11	0,0000%
S11_estu_estudiante	0,0001%
S11_estu_depto_reside	0,3194%
S11_fami_estratovivienda	1,0143%
S11_estu_inse_individual	44,2863%
S11_fami_tieneinternet	1,0196%
S11_cole_naturaleza	0,0002%
S11_cole_area_ubicacion	0,0177%
S11_cole_bilingue	8,8991%
S11_cole_calendario	0,0072%
S11_cole_jornada	0,0046%
S11_punt_c_naturales	18,9932%
S11_punt_ingles	19,0087%
S11_punt_lectura_critica	18,9932%
S11_punt_matematicas	18,9931%
S11_punt_sociales_ciudadanas	18,9932%
S11_punt_global	43,8061%
S11_percentil_global	66,6970%

Nombre de la variable	Porcentaje de valores faltantes
estu_consecutivo_sbpro	0,0000%
periodo_sbpro	0,0000%
SP_estu_genero	0,0002%
SP_estu_depto_reside	15,3050%
SP_fami_estratovivienda	3,2282%
SP_estu_nse_individual	4,0847%
SP_fami_educacionmadre	3,0727%
SP_fami_educacionpadre	6,0329%
SP_fami_tieneinternet	2,6775%
SP_inst_nombre_institucion	1,0433%
SP_estu_prgm_academico	1,0433%
SP_mod_comuni_escrita_punt	0,7406%
SP_mod_competen_ciudada_punt	0,0000%
SP_mod_ingles_punt	0,0336%
SP_mod_lectura_critica_punt	0,0000%
SP_mod_razona_cuantitat_punt	0,0000%
SP_punt_global	0,0008%
SP_percentil_global	0,0657%
rezago_semestres	0,0000%

Se observaron variables cuyo porcentaje de faltantes era amplio, generalmente esto está explicado por la eliminación de datos anormales, cambiando valores no validos por “NA’s” los que son los valores faltantes.

Reproducibilidad y automatización

Para reproducir la base de datos desde cualquier dispositivo ordenador se requiere el uso del entorno de desarrollo integrado RStudio que usa el lenguaje de programación “R”.

Al tener el entorno de programación y las bases de datos la reproducibilidad se da mediante la subida de archivos de la base de datos al entorno y distintos códigos con distintas funciones, los cuales están agrupados en un código “maestro” que los reproduce automáticamente. Para que este mismo sea reproducible por cualquier persona (aún con poco conocimiento sobre el entorno) se trabajó con librerías y comandos que “obligan” al dispositivo a realizar pasos que normalmente realizaría una persona previa a la ejecución (como instalar librerías).

El flujo automatizado o código maestro se encuentra automatizado de la siguiente manera:

- Paso 0: Siendo el único paso que requiere la intervención de la persona que desee reproducir la base de datos, este se basa en la subida de los archivos descargados en la plataforma Data ICFES al entorno de RStudio.
- Paso 1 – Homologación de variables: Este paso tiene como objetivo homologar periodos especiales como el 2014-1 que reemplaza nombres de variables que en estos periodos son diferentes por una homologada.
- Paso 2 – Procesamiento y consolidación del Saber 11: Este paso tiene como objetivo procesar todos los archivos del Saber 11 y crear una nueva base de datos única.
- Paso 3 – Procesamiento y consolidación del Saber Pro: Este paso tiene como objetivo procesar todos los archivos del Saber Pro y crear una nueva base de datos única.
- Paso 4 – Cruces, filtrado temporal y cálculo de rezagos: Realiza un filtrado de la base de datos de cruces del Saber 11 y Saber Pro, esto para mantener rezagos.
- Paso 5 – Unificación de bases y ordenamientos por bloques: Este paso tiene como objetivo unificar las bases de datos Saber 11 y Saber Pro para posteriormente darle un orden mediante bloques de periodos.
- Paso 6 – Detección, conteo y eliminación de anomalías numéricas: En este paso se analiza la base de datos unificada para hallar anomalías con los resultados, realiza un conteo (importante para los descriptivos) y luego los elimina de la base de datos final.
- Paso 7 – Limpieza final y depuración general de la base unificada.
- Paso 8 – Generación de estadísticas descriptivas y exploratorias: Este paso tiene como objetivo realizar un análisis estadístico de las variables, principalmente las numéricas.
- Paso 9 – Modelos econométricos, valor agregado, brechas y regiones: En este caso se realiza un análisis económico y de brechas sociales, variables importantes para estudios posteriores.

Si el objetivo es agregar un nuevo año de estudio, se debe descargar el archivo tipo .txt de la plataforma Data ICFES, luego se guarda en la carpeta correspondiente al entorno de RStudio y se ejecutan los scripts (códigos). En el caso de que la nueva base de datos tenga variables nuevas o nombradas de diferente manera, se debe modificar el diccionario de variables.

Limitaciones

Las limitaciones fueron principalmente dadas por inconsistencias y variables nombradas de diferente manera.

Una de las principales fue el tipo de calificación que tenían las pruebas Saber Pro en los periodos 2014 y 2015 ya que a falta de información de recalificaciones de las competencias no fue posible utilizar o combinar todos los años de saber pro en una base de datos limpia, consolidada y coherente respecto a puntajes de las competencias.

No sólo se tuvo limitaciones respecto a puntajes, también se encontraron personas que repitieron la prueba más de una vez y/o realizaron la Saber 11 posterior a la Saber Pro. En el caso de las personas que realizaron la prueba Saber 11 en más de una ocasión se mantuvo el primer puntaje o registro en la base de datos; luego, para las personas que realizaron la prueba Saber 11 posterior a la Saber Pro se eliminaron los cruces cuyo rezago fuera menor a un año, esto con el objetivo de mantener una línea temporal en las pruebas.

Uso de IA

Durante el desarrollo del proyecto se utilizó inteligencia artificial como herramienta de apoyo para la organización del informe técnico, revisión de redacción, estructuración de la documentación del proceso de integración de datos y medio de ayuda para la generación de algoritmos para la limpieza, estructuración, homologación y cruce de datos.

Además, todas las decisiones relacionadas con la selección de variables, reglas de vinculación, tratamiento de datos y métricas de calidad fueron definidas y comprobadas por el grupo.

La bitácora de uso fue anexada fuera del documento técnico.