

ENTREGABLE 6. REGISTRO DE DECISIONES

Estadística Industrial

1. Introducción

Durante la construcción y consolidación de la base de datos del proyecto fue necesario tomar diferentes decisiones metodológicas relacionadas con la selección de variables, la integración de las bases de Saber 11 y Saber Pro, el tratamiento de los periodos, la construcción de nuevas variables, la identificación de registros duplicados y el tratamiento de los datos faltantes.

El propósito de este registro es documentar las principales decisiones tomadas durante el proceso, indicando la situación que se presentó, las alternativas consideradas, la decisión adoptada, las razones que llevaron al grupo a escogerla y las consecuencias que tuvo sobre la base de datos y los análisis posteriores.

El proyecto se delimitó a estudiantes que realizaron la prueba Saber 11 entre 2010 y 2025 y que posteriormente realizaron la prueba Saber Pro entre 2014 y 2025. A partir de esta población se construyó una base consolidada que busca relacionar el desempeño en ambas pruebas con diferentes características del estudiante y de su contexto.

2. Registro cronológico de decisiones

N°	Etapas	Situación o encrucijada	Alternativas consideradas	Decisión tomada	Justificación	Impacto sobre los datos y/o análisis
1	1. Definición del alcance temporal	Era necesario establecer qué periodos de Saber 11 y Saber Pro serían considerados en el proyecto.	Trabajar con todos los periodos disponibles o limitar el análisis a los periodos establecidos para el proyecto.	Se trabajó con estudiantes que realizaron Saber 11 entre 2010 y 2025 y que posteriormente realizaron Saber Pro entre 2014 y 2025.	Estos fueron los periodos definidos para el desarrollo del proyecto y permiten estudiar la trayectoria entre las dos pruebas dentro del intervalo establecido.	Se delimitó el universo temporal de la investigación. Esto permitió establecer qué registros podían participar en la construcción de la base y posteriormente calcular el tiempo transcurrido entre ambas pruebas.
2	2. Selección de variables	Las bases originales contenían una cantidad considerable de variables y era necesario definir cuáles serían utilizadas en el análisis.	Utilizar todas las variables disponibles o seleccionar aquellas relacionadas con los objetivos del proyecto.	El grupo seleccionó las variables que consideró que podían afectar o estar relacionadas con el desempeño del estudiante, incluyendo puntajes, situación familiar y estrato socioeconómico, entre otras características relevantes.	Se buscó que la base no se limitara a los resultados de las pruebas, sino que también permitiera considerar características del contexto del estudiante que pudieran relacionarse con su desempeño.	La base final se concentró en variables consideradas relevantes para el proyecto, reduciendo información que no aportaba directamente al enfoque del análisis.
3	3. Vinculación de Saber 11 y Saber Pro	Era necesario relacionar correctamente los registros de un mismo estudiante entre las dos pruebas.	Construir una llave propia con variables de las bases o utilizar la información oficial de cruces proporcionada por el ICFES.	Se utilizó la información de Cruces Saber 11–Saber Pro del ICFES para realizar la vinculación.	La base de cruces fue diseñada específicamente para relacionar información de las dos pruebas, por lo que ofrecía una alternativa más adecuada que construir manualmente una correspondencia.	Se pudo integrar la información de Saber 11 y Saber Pro conservando la relación entre los estudiantes. Esto hizo posible estudiar conjuntamente sus características y resultados en ambas pruebas.
4	4. Integración mediante RStudio	Las diferentes bases debían ser limpiadas y posteriormente integradas. Realizar este procedimiento manualmente podía aumentar el riesgo de errores.	Realizar la integración manualmente en Excel o utilizar programación en RStudio.	Se utilizó RStudio mediante códigos para limpiar, transformar y unir las bases.	La programación permitió automatizar el proceso y repetir las operaciones de manera más controlada.	La integración quedó definida mediante un procedimiento programado, lo que permitió volver a ejecutar y modificar los procesos cuando fue necesario.
5	5. Homologación de variables	Las variables podían presentar diferencias de nombres o estructura entre las bases utilizadas.	Mantener los nombres originales o homologar las variables equivalentes.	Se homologaron las variables que representaban información equivalente para facilitar su integración.	Era necesario trabajar con una estructura coherente para evitar tratar como variables diferentes aquellas que representaban una misma característica.	Se facilitó la integración y manipulación posterior de las variables, reduciendo la posibilidad de confusiones durante el análisis.
6	6. Diferenciación de variables de las dos pruebas	Después de integrar Saber 11 y Saber Pro, algunas variables tenían nombres iguales o similares.	Mantener los nombres originales o modificarlos para identificar la prueba de procedencia.	Se agregaron los prefijos S11_ a las variables de Saber 11 y SP_ a las variables de Saber Pro.	Se necesitaba diferenciar claramente la información de cada prueba una vez que ambas estuvieran dentro de la misma base.	Se evitó la confusión entre variables correspondientes a las dos pruebas y fue posible identificar inmediatamente el

N°	Etapas	Situación o encrucijada	Alternativas consideradas	Decisión tomada	Justificación	Impacto sobre los datos y/o análisis
						origen de cada variable durante los análisis posteriores.
7	7. Tratamiento de los periodos	Era necesario trabajar correctamente con los periodos de presentación de las pruebas para establecer cuál se realizó primero.	Mantener los códigos originales de los periodos o transformarlos para poder compararlos temporalmente.	Los periodos fueron transformados y tratados de manera que permitieran establecer correctamente el orden cronológico entre Saber 11 y Saber Pro.	El proyecto requiere que la trayectoria corresponda a Saber 11 → Saber Pro. Por lo tanto, era necesario poder comparar los periodos aunque estuvieran expresados mediante códigos como 2015-1, 2015-2, 2016-1, etc.	Los periodos pudieron utilizarse para determinar la diferencia temporal entre las pruebas y posteriormente construir la variable de rezago.
8	8. Creación de rezago_semestres	Se necesitaba una variable que indicara cuántos periodos habían transcurrido entre Saber 11 y Saber Pro.	Trabajar únicamente con los periodos originales o crear una variable derivada.	Se creó la variable rezago_semestres para representar la diferencia entre los periodos de ambas pruebas.	El grupo consideró más práctico disponer de una medida directa del tiempo transcurrido entre las dos pruebas, utilizando los periodos como unidad temporal.	El tiempo entre Saber 11 y Saber Pro quedó incorporado directamente en la base y pudo utilizarse posteriormente como variable de análisis.
9	9. Establecimiento del rezago mínimo	Al calcular el rezago aparecieron registros con valores de cero o negativos.	Mantener estos registros o excluirlos de la base.	Se estableció un mínimo de un periodo y se eliminaron los registros con rezago igual o inferior a cero.	Se consideró razonable que un estudiante realizara primero Saber 11 y posteriormente Saber Pro, con al menos un periodo de diferencia. Un valor de cero no representa una separación temporal y un valor negativo contradice la secuencia establecida para el proyecto.	Se excluyeron registros que no representaban la trayectoria temporal definida. Como consecuencia, los análisis relacionados con el rezago se realizan sobre estudiantes que cumplen la condición de haber presentado primero Saber 11 y posteriormente Saber Pro.
10	10. Revisión de valores faltantes	Las variables seleccionadas presentaban diferentes niveles de datos faltantes.	Eliminar todas las variables que tuvieran faltantes, completar artificialmente los valores o conservar las variables relevantes manteniendo los faltantes.	Se decidió no eliminar automáticamente una variable por presentar datos faltantes. Las variables consideradas relevantes permanecieron en la base y los valores no disponibles se conservaron como NA.	La presencia de datos faltantes no significaba necesariamente que una variable dejara de ser útil. Algunas variables seguían siendo relevantes para los objetivos del proyecto y eliminar toda variable con faltantes habría implicado perder información potencialmente importante.	Se conservaron variables relevantes aun cuando presentaran cantidades importantes de información faltante. Los análisis posteriores deberán considerar que el número de observaciones disponibles puede variar dependiendo de la variable utilizada.
11	11. Identificación de variables con información prácticamente inexistente	Durante la revisión del diccionario actualizado se identificaron dos variables con aproximadamente 99,9992 % de datos faltantes: SP_fami_ingreso_fmiliar_mensual y SP_estu_trabaja_actualmente.	Conservarlas a pesar de su nivel de faltantes o excluirlas de la base final.	Se decidió eliminar estas dos variables de la base final.	En estas dos variables la cantidad de información disponible era prácticamente inexistente. Por lo tanto, mantenerlas no aportaba suficiente información observable para los objetivos del análisis y podía generar dificultades en los análisis posteriores.	Se redujo la cantidad de variables de la base final en dos. La información restante quedó más enfocada en variables con una disponibilidad que permitiera utilizarlas efectivamente en el análisis.

N°	Etapas	Situación o encrucijada	Alternativas consideradas	Decisión tomada	Justificación	Impacto sobre los datos y/o análisis
12	12. Criterio para conservar otras variables con faltantes	Otras variables también presentaban porcentajes importantes de valores faltantes, pero tenían relación con los objetivos del proyecto.	Eliminarlas por su porcentaje de faltantes o conservarlas debido a su relevancia.	Se conservaron las variables que, a pesar de presentar faltantes, continuaban siendo relevantes para el análisis.	La decisión no se basó únicamente en un porcentaje de faltantes. También se tuvo en cuenta la utilidad de la variable para estudiar el desempeño y el contexto del estudiante.	Se evitó perder variables relevantes solamente por presentar información incompleta. Al mismo tiempo, se diferenciaron de las dos variables cuya disponibilidad era prácticamente nula y que sí fueron eliminadas.
13	13. Tratamiento de valores no disponibles	Algunos valores no contenían información que pudiera utilizarse directamente en el análisis.	Asignar un valor para completar el registro o conservar la ausencia de información.	Los valores que no estaban disponibles se mantuvieron como NA.	No se consideró adecuado inventar o asignar valores que no estuvieran respaldados por la información disponible.	Los análisis posteriores podrán identificar los valores faltantes de manera explícita, evitando que se confundan con valores reales.
14	14. Duplicados durante la integración	Durante el proceso de integración se encontraron dos registros duplicados con exactamente la misma información.	Mantener los dos registros o conservar solamente una observación.	Se eliminaron los registros duplicados y se conservó una sola copia.	Al tener exactamente la misma información, mantener ambos registros habría significado contabilizar dos veces la misma observación.	Se evitó duplicar artificialmente el peso de esas observaciones en la base. Esto protege los análisis posteriores de frecuencias, conteos y estadísticas que dependen del número de registros.
15	15. Comprobación de duplicados	Después de eliminar los registros repetidos era necesario comprobar que el proceso de depuración hubiera funcionado correctamente.	Confiar únicamente en el código utilizado o realizar verificaciones adicionales.	Se realizaron comprobaciones en RStudio y se revisó una muestra de registros para confirmar la ausencia de duplicados evidentes.	Se consideró necesario verificar el resultado del procesamiento y no asumir que la ejecución del código garantizaba por sí sola que la base estuviera correctamente depurada.	Se obtuvo una verificación adicional de la estructura de la base antes de continuar con los análisis posteriores.
16	16. Validación de la secuencia temporal	Era necesario comprobar que los registros utilizados cumplieran la secuencia Saber 11 → Saber Pro.	Aceptar todos los cruces generados o revisar la relación temporal mediante filtros y cálculos.	Se revisó la relación entre los periodos y se utilizaron los criterios establecidos para excluir los registros con rezago igual o inferior a cero.	El análisis se centra en estudiantes que realizaron primero Saber 11 y posteriormente Saber Pro.	La base utilizada para estudiar el rezago quedó restringida a registros que cumplen la secuencia temporal definida por el grupo.
17	17. Corrección y ajuste de códigos	Durante el procesamiento algunos códigos no producían exactamente el resultado esperado.	Mantener el código original o revisarlo y modificarlo.	Los códigos fueron revisados y ajustados cuando los resultados no correspondían con lo esperado.	El grupo verificó los resultados obtenidos en lugar de asumir que un código era correcto únicamente porque se ejecutara sin generar un error.	Se corrigieron procedimientos antes de utilizarlos para generar la base final, reduciendo el riesgo de que errores de programación se trasladaran a los análisis posteriores.
18	18. Uso de rutas relativas	El proyecto era grupal y los archivos podían encontrarse en ubicaciones diferentes dependiendo del computador utilizado.	Utilizar rutas absolutas o establecer rutas relativas.	Se utilizaron rutas relativas para facilitar la ejecución de los códigos en diferentes equipos.	Esto permitió que el código no dependiera de una ruta específica de un único computador y facilitó el trabajo colaborativo.	Los integrantes pudieron ejecutar nuevamente el procesamiento sin tener que modificar constantemente las rutas de los archivos, facilitando

N°	Etapas	Situación o encrucijada	Alternativas consideradas	Decisión tomada	Justificación	Impacto sobre los datos y/o análisis
						la reproducibilidad del procedimiento.
19	19. Uso de inteligencia artificial como apoyo	La construcción de los códigos y la organización del trabajo requirió apoyo para resolver problemas de programación y estructuración.	Realizar todo el código manualmente o utilizar herramientas de inteligencia artificial como apoyo.	Se utilizaron ChatGPT, Gemini y Claude como herramientas de apoyo.	Estas herramientas permitieron obtener propuestas de código y alternativas para resolver problemas durante el procesamiento.	Se redujo el tiempo necesario para desarrollar y modificar algunos procedimientos, pero cada código tuvo que ser ejecutado y revisado antes de incorporarlo al proceso definitivo.
20	20. Verificación de las respuestas generadas por IA	Los códigos generados por inteligencia artificial podían contener errores o realizar acciones diferentes a las solicitadas.	Utilizar directamente las respuestas o comprobarlas antes de incorporarlas al proyecto.	Se decidió verificar los códigos y resultados antes de utilizarlos.	La responsabilidad sobre el procedimiento debía permanecer en el grupo. La IA fue considerada una herramienta de apoyo y no una fuente que pudiera asumirse como correcta automáticamente.	Los códigos que no producían el resultado esperado pudieron ser identificados y corregidos antes de que sus resultados fueran incorporados a la base final.

3. Síntesis de las decisiones metodológicas

La construcción de la base de datos requirió tomar decisiones relacionadas tanto con la estructura de la información como con la calidad y utilidad de los registros.

El primer criterio establecido fue la delimitación temporal. El proyecto se concentró en estudiantes que realizaron Saber 11 entre 2010 y 2025 y que posteriormente realizaron Saber Pro entre 2014 y 2025. Esta condición permitió establecer una trayectoria temporal concreta entre las dos pruebas.

Posteriormente se seleccionaron las variables que el grupo consideró relevantes para estudiar el desempeño de los estudiantes. La selección incluyó los puntajes obtenidos en las pruebas, pero también variables relacionadas con la situación familiar y el estrato socioeconómico, buscando que el análisis pudiera considerar tanto el desempeño académico como características del contexto del estudiante.

La relación entre Saber 11 y Saber Pro se realizó utilizando la información de cruces proporcionada por el ICFES. Posteriormente, mediante RStudio, se desarrollaron los procesos necesarios para limpiar, transformar e integrar la información.

Una de las decisiones importantes durante la integración fue diferenciar las variables de acuerdo con su prueba de origen. Para esto se utilizaron los prefijos S11_ y SP_. Esta modificación permitió evitar confusiones una vez que la información de ambas pruebas se encontraba dentro de una misma base.

También fue necesario transformar los periodos para poder establecer correctamente la diferencia temporal entre las pruebas. A partir de esto se construyó `rezago_semestres`, estableciendo como condición que existiera como mínimo un periodo entre Saber 11 y Saber Pro.

En relación con los datos faltantes, el grupo no utilizó el porcentaje de faltantes como un criterio automático para eliminar una variable. Se tuvo en cuenta también la utilidad de la variable para los objetivos del proyecto. Esto permitió conservar variables relevantes aunque presentaran cantidades importantes de información faltante.

Sin embargo, durante la revisión del diccionario actualizado se identificaron dos variables que constituían una excepción clara: `SP_fami_ingreso_fmiliar_mensual` y `SP_estu_trabaja_actualmente`, ambas con aproximadamente 99,9992 % de datos faltantes. Debido a que prácticamente no presentaban información disponible, se decidió eliminarlas de la base final.

Esta decisión permitió establecer una diferencia entre tener datos faltantes y tener prácticamente toda la variable sin información. Mientras las variables relevantes con faltantes podían seguir aportando información en los registros disponibles, estas dos variables no contaban con una cantidad suficiente de observaciones para justificar su permanencia.

Finalmente, durante la integración se encontraron dos registros duplicados con información exactamente igual. Estos fueron eliminados para evitar que una misma observación fuera contabilizada más de una vez.

4. Impacto general de las decisiones sobre la base

Las decisiones tomadas durante la construcción de la base tuvieron diferentes efectos sobre el conjunto de datos.

La delimitación de los periodos estableció las condiciones de inclusión de los estudiantes y permitió que el análisis estuviera enfocado en una trayectoria definida entre Saber 11 y Saber Pro.

La selección de variables redujo la información utilizada a aquella que el grupo consideró relacionada con los objetivos del proyecto. Esto permitió trabajar con una base más enfocada en el desempeño y en las características familiares y socioeconómicas de los estudiantes.

La vinculación mediante los cruces del ICFES permitió relacionar las dos pruebas y, por lo tanto, disponer de información correspondiente a diferentes momentos de la trayectoria del estudiante dentro de un mismo registro.

La transformación de los periodos y la creación de rezago_semestres permitieron incorporar explícitamente la dimensión temporal al análisis. La eliminación de registros con rezago igual o inferior a cero aseguró que esta variable representara únicamente trayectorias donde Saber 11 precediera a Saber Pro.

El tratamiento de los datos faltantes permitió conservar variables relevantes sin crear información artificial. Como consecuencia, algunos análisis posteriores pueden trabajar con diferentes cantidades de observaciones dependiendo de la variable utilizada.

Por otro lado, la eliminación de las dos variables con aproximadamente 99,9992 % de faltantes evitó conservar información prácticamente inexistente en la base final. Esta decisión redujo la cantidad de variables disponibles, pero aumentó la utilidad potencial de la información conservada.

La eliminación de los dos registros duplicados también tuvo un efecto directo sobre la cantidad de observaciones, evitando que una misma información fuera contabilizada dos veces.

5. Validación de la base consolidada

Después de realizar la integración y depuración de las bases, se realizaron diferentes verificaciones para comprobar que los resultados fueran coherentes con las decisiones metodológicas establecidas.

Se verificó la diferenciación entre las variables de Saber 11 y Saber Pro mediante los prefijos correspondientes y se revisó el tratamiento de los periodos para garantizar que pudieran utilizarse para establecer la secuencia temporal entre las pruebas.

También se revisó la variable `rezago_semestres` y se aplicó el criterio establecido de mínimo un periodo. Los registros con valores iguales o inferiores a cero fueron excluidos porque no representaban la trayectoria definida por el grupo.

Durante la revisión de duplicados se identificaron dos registros con información exactamente igual. Estos fueron eliminados y posteriormente se realizaron comprobaciones adicionales para revisar la consistencia de la base.

También se revisaron los resultados producidos por los códigos utilizados en RStudio. Esto fue especialmente importante porque parte del código fue desarrollado con apoyo de herramientas de inteligencia artificial.

De esta manera, la validación no se limitó a comprobar que los códigos se ejecutaran correctamente, sino que también se revisó si los resultados obtenidos correspondían con lo que metodológicamente se esperaba.

6. Uso de herramientas de inteligencia artificial

Durante el proyecto se utilizaron ChatGPT, Gemini y Claude como herramientas de apoyo para desarrollar códigos, solucionar problemas de programación y organizar parte del trabajo.

El uso de estas herramientas permitió obtener alternativas de código y agilizar algunas etapas del procesamiento de la información. Sin embargo, el grupo reconoció que una herramienta de inteligencia artificial puede generar código incorrecto o realizar acciones diferentes a las solicitadas.

Por esta razón, los códigos generados no fueron utilizados automáticamente. Cada procedimiento debía ejecutarse y posteriormente revisarse para determinar si el resultado correspondía con el objetivo planteado.

Cuando un código no producía el resultado esperado, se revisaba y modificaba antes de continuar con el proceso. De esta forma, la inteligencia artificial se utilizó como apoyo técnico, mientras

que la responsabilidad sobre las decisiones metodológicas y la validación de los resultados permaneció en los integrantes del grupo.

7. Limitaciones del proceso

Una de las principales limitaciones encontradas durante la construcción de la base fue la existencia de diferentes niveles de información disponible entre las variables y los periodos trabajados.

Esto hizo necesario distinguir entre variables que simplemente presentaban algunos valores faltantes y variables cuya información disponible era prácticamente inexistente. En el primer caso, las variables relevantes fueron conservadas y los faltantes se representaron como NA. En el segundo caso, como ocurrió con SP_fami_ingreso_familiar_mensual y SP_estu_trabaja_actualmente, se decidió retirar las variables de la base final.

Otra limitación estuvo relacionada con la necesidad de verificar continuamente los resultados producidos por los códigos. El uso de programación facilitó considerablemente el procesamiento de grandes cantidades de información, pero un error en una instrucción podía afectar el resultado de todo el procedimiento.

Finalmente, el uso de herramientas de inteligencia artificial implicó una responsabilidad adicional de revisión, debido a que los códigos sugeridos podían no corresponder exactamente con lo que se necesitaba realizar.

8. Reflexión final

El desarrollo de este proyecto permitió comprender que la preparación de los datos constituye una parte fundamental del análisis estadístico. Antes de aplicar métodos estadísticos es necesario establecer qué información se utilizará, cómo se relacionarán las diferentes fuentes y qué criterios se aplicarán para garantizar que la base sea coherente con los objetivos del estudio.

Una de las principales decisiones fue trabajar con estudiantes que realizaron Saber 11 entre 2010 y 2025 y posteriormente Saber Pro entre 2014 y 2025. Esto permitió establecer una trayectoria temporal y construir una medida del tiempo transcurrido entre ambas pruebas.

También fue importante diferenciar entre las variables de Saber 11 y Saber Pro mediante los prefijos S11_ y SP_, ya que esto permitió trabajar con información de ambas pruebas sin confundir variables que tenían nombres similares o iguales.

El tratamiento de los datos faltantes también representó una decisión importante. El grupo no consideró adecuado eliminar automáticamente una variable por presentar faltantes, debido a

que algunas variables continuaban siendo relevantes para los objetivos del proyecto. Sin embargo, se estableció una diferencia cuando la disponibilidad de información era prácticamente nula. Por esta razón se eliminaron las dos variables que presentaban aproximadamente 99,9992 % de datos faltantes.

Asimismo, la identificación y eliminación de los dos registros duplicados permitió evitar que una misma observación fuera contabilizada dos veces y afectara los análisis posteriores.

Finalmente, el uso de RStudio y de herramientas de inteligencia artificial facilitó el procesamiento de las bases, pero también evidenció la importancia de verificar los resultados. La ejecución de un código no fue considerada suficiente para garantizar su validez; fue necesario revisar que el resultado coincidiera con los criterios establecidos por el grupo.

En conclusión, las decisiones registradas permitieron transformar información proveniente de diferentes periodos y fuentes en una base consolidada y estructurada para las siguientes etapas del proyecto. Además, esta bitácora deja documentados los principales criterios utilizados para que el proceso de construcción de la base pueda ser comprendido y evaluado.